

PROYECTO HOUSE PRICES

Contexto y justificación

El análisis de información proveniente del mercado inmobiliario en México constituye una oportunidad relevante para el estudio de relaciones entre variables económicas, espaciales y estructurales. El conjunto de datos seleccionado permite explorar la variabilidad en los precios de vivienda en función de diversas características observables. En este contexto, el desarrollo de modelos explicativos y predictivos se plantea como una aproximación metodológica orientada a comprender la dinámica del mercado.

El sector inmobiliario representa uno de los principales indicadores del desarrollo económico, ya que refleja el comportamiento de la inversión, la demanda de vivienda y las condiciones socioeconómicas de la población. En ciudades como Toluca, donde el crecimiento urbano ha impulsado la construcción de nuevos desarrollos habitacionales, resulta de interés identificar cuáles son las características que tienen mayor influencia en el precio de una propiedad. Variables como el área de construcción, el número de baños y la cantidad de habitaciones suelen ser factores determinantes para compradores, vendedores e inversionistas.

Desde una perspectiva analítica, el empleo de técnicas de regresión lineal múltiple permite cuantificar la relación existente entre estas características y el precio de las viviendas, proporcionando evidencia estadística sobre la importancia de cada variable explicativa. Asimismo, la aplicación de pruebas de diagnóstico, como el análisis de multicolinealidad, normalidad de los residuos, heterocedasticidad y ANOVA, permite validar los supuestos del modelo y evaluar su capacidad predictiva.

La relevancia práctica de este estudio radica en que los resultados pueden servir como apoyo para la toma de decisiones en el ámbito inmobiliario, facilitando la estimación de precios y la identificación de los factores que generan mayor valor en una vivienda. Además, este análisis constituye un ejercicio aplicado de técnicas estadísticas que fortalece la interpretación de datos reales y promueve el uso de herramientas cuantitativas para la solución de problemas relacionados con la gestión empresarial y el análisis económico.

1. Planteamiento del problema

El precio de una vivienda está determinado por múltiples factores, entre ellos sus características físicas, su ubicación y las condiciones del mercado inmobiliario. Sin embargo, no siempre es evidente cuál es el grado de influencia que ejerce cada una de estas variables sobre el valor de una propiedad. Esta situación dificulta la estimación objetiva de precios y la toma de decisiones por parte de compradores, vendedores, inversionistas y desarrolladores inmobiliarios.

En el caso de las viviendas ubicadas en Toluca, Estado de México, resulta de interés analizar si variables como el área de construcción, el número de baños y la cantidad de habitaciones presentan una relación significativa con el precio de venta de los inmuebles. Para ello, es necesario aplicar herramientas estadísticas que permitan cuantificar dicha relación y evaluar la capacidad de estas variables para explicar el comportamiento del precio.

El presente estudio aborda este problema mediante la construcción de un modelo de regresión lineal múltiple utilizando información de 1,658 viviendas, previamente depurada para eliminar registros con datos faltantes. El análisis busca determinar la influencia de las variables independientes (área, baños y habitaciones) sobre la variable dependiente (precio), así como verificar el cumplimiento de los supuestos estadísticos del modelo mediante pruebas de multicolinealidad, normalidad de los residuos, homocedasticidad y análisis de varianza.

Con base en lo anterior, la pregunta de investigación que guía este trabajo es:

¿En qué medida el área de construcción, el número de baños y la cantidad de habitaciones influyen en el precio de venta de las viviendas en Toluca, y qué tan adecuado es un modelo de regresión lineal múltiple para explicar y predecir dicho comportamiento?

Esta versión está alineada con el contexto del proyecto y delimita claramente el fenómeno de estudio, las variables involucradas y la relevancia del análisis.

Objetivo general

Analizar la relación entre las características estructurales, geográficas y categóricas de los inmuebles y una variable de interés seleccionada, mediante la formulación de un modelo de regresión lineal múltiple que permita evaluar su capacidad explicativa y predictiva.

Objetivos específicos

- 1.1 Examinar la estructura y naturaleza de las variables disponibles en el conjunto de datos.
- 1.2 Analizar el comportamiento de variables categóricas mediante la comparación de medias respecto a la variable dependiente.
- 1.3 Transformar variables categóricas en variables numéricas con base en criterios analíticos derivados del comportamiento observado.
- 1.4 Evaluar relaciones entre variables mediante análisis de correlación.
- 1.5 Examinar la presencia de multicolinealidad entre variables independientes.
- 1.6 Proponer un modelo de regresión lineal múltiple.
- 1.7 Evaluar el cumplimiento de los supuestos del modelo.
- 1.8 Analizar la capacidad predictiva del modelo en términos de interpolación y extrapolación.

Marco analítico y desarrollo del estudio

1.9 Definición de la variable dependiente

La variable dependiente seleccionada para este estudio es el precio de la vivienda, medido en las unidades monetarias reportadas en la base de datos. Esta variable representa el resultado o fenómeno de interés, ya que refleja el valor de mercado asignado a cada inmueble y constituye el elemento que se busca explicar mediante las características físicas de las propiedades.

La elección del precio como variable dependiente es pertinente debido a que es el principal indicador utilizado por compradores, vendedores, desarrolladores e inversionistas para evaluar el valor de un inmueble. Además, el precio está influenciado por diversos factores, entre los que destacan el área de construcción, el número de baños y la cantidad de habitaciones, variables que fueron consideradas como explicativas dentro del modelo de regresión lineal múltiple desarrollado en esta investigación.

Desde el punto de vista analítico, modelar el precio de las viviendas permite identificar la magnitud y dirección de la influencia de cada variable independiente, así como estimar el valor esperado de una propiedad con base en sus características. Esto facilita la comprensión del comportamiento del mercado inmobiliario y proporciona información útil para la toma de decisiones relacionadas con la compra, venta, valuación e inversión en bienes raíces.

Por lo tanto, el precio de la vivienda constituye la variable respuesta del estudio, ya que sobre él recaen los efectos de las variables explicativas y es el elemento central para evaluar la capacidad predictiva y explicativa del modelo estadístico propuesto.

1.10 Análisis de variables categóricas

En la base de datos original se contaba con la variable Ubicación, la cual correspondía a una variable categórica que identificaba la dirección o zona de cada vivienda. Sin embargo, debido a la gran cantidad de categorías diferentes y al objetivo de construir un modelo de regresión lineal

basado en variables cuantitativas, esta variable fue eliminada durante el proceso de depuración y preparación de los datos.

Como consecuencia, el conjunto de datos utilizado para el análisis final quedó conformado únicamente por las variables cuantitativas Área, Baños, Habitaciones y Precio. En estas condiciones, no fue posible realizar comparaciones de medias entre categorías ni aplicar pruebas estadísticas como la prueba t de Student o el ANOVA de un factor, ya que dichas técnicas requieren la existencia de una variable categórica independiente.

Por lo tanto, el análisis se centró en estudiar la relación entre las variables cuantitativas mediante un modelo de regresión lineal múltiple, evaluando la influencia del área de construcción, el número de baños y la cantidad de habitaciones sobre el precio de las viviendas, así como verificando el cumplimiento de los supuestos estadísticos del modelo.

1.11 Codificación de variables categóricas

Durante la etapa de preparación de los datos se identificó que la única variable categórica disponible era Ubicación, la cual contenía un gran número de categorías correspondientes a direcciones o zonas específicas de las viviendas. Debido a la elevada diversidad de valores y a que el objetivo del estudio fue analizar la influencia de variables cuantitativas sobre el precio de los inmuebles, esta variable fue excluida del conjunto de datos antes de la estimación del modelo de regresión.

Por esta razón, no fue necesario realizar un proceso de codificación de variables categóricas a variables numéricas, ya que el modelo final se desarrolló únicamente con las variables cuantitativas Área, Baños, Habitaciones y Precio.

La decisión de no codificar la variable categórica se considera pertinente, debido a que su inclusión hubiera requerido la generación de un gran número de variables indicadoras (variables dummy), incrementando la complejidad del modelo sin contribuir al objetivo principal del estudio, el cual consistió en evaluar la relación entre las características físicas de las viviendas y su precio de venta.

En consecuencia, el análisis estadístico se realizó exclusivamente con variables numéricas, permitiendo obtener un modelo de regresión lineal múltiple más sencillo, interpretable y consistente con los objetivos de la investigación.

1.12 Análisis de relaciones entre variables

Con el propósito de identificar la intensidad de la relación entre las variables del estudio, se realizó un análisis de asociación mediante la matriz de correlación y el mapa de calor. Este procedimiento permitió evaluar el grado de relación lineal entre las variables independientes (Área, Baños y Habitaciones) y la variable dependiente (Precio), así como detectar posibles problemas de multicolinealidad entre las variables explicativas.

Los resultados muestran que existe una relación positiva entre las características físicas de las viviendas y su precio de venta, lo que indica que, en términos generales, las propiedades con mayor área de construcción, mayor número de baños y mayor cantidad de habitaciones tienden a presentar precios más elevados. Estas asociaciones respaldan la selección de dichas variables como predictores dentro del modelo de regresión lineal múltiple.

Adicionalmente, se calculó el Factor de Inflación de la Varianza (VIF) para evaluar la presencia de multicolinealidad. Los valores obtenidos fueron 1.864 para Área, 1.628 para Baños, 2.149 para Habitaciones y 1.431 para Precio. Todos estos valores son considerablemente menores al umbral de referencia de 5, lo que indica que no existe una correlación excesiva entre las variables independientes y, por tanto, no hay evidencia de problemas importantes de multicolinealidad.

En conjunto, estos resultados permiten concluir que las variables explicativas presentan relaciones consistentes con la variable dependiente y que pueden incorporarse simultáneamente en el modelo de regresión sin afectar la estabilidad de las estimaciones. Esto proporciona una base estadística adecuada para interpretar la influencia del área, el número de baños y la cantidad de habitaciones sobre el precio de las viviendas en Toluca.

1.13 Evaluación de multicolinealidad

La multicolinealidad se presenta cuando dos o más variables independientes muestran una alta correlación entre sí, lo que puede provocar inestabilidad en las estimaciones de los coeficientes de regresión, aumentar sus errores estándar y dificultar la interpretación del efecto individual de cada variable dentro del modelo.

Para evaluar este supuesto se calculó el Factor de Inflación de la Varianza (Variance Inflation Factor, VIF) para cada una de las variables independientes incluidas en el modelo. Los resultados obtenidos fueron los siguientes:

VARIABLE	VIF
AREA	1.864
BAÑOS	1.628
HABITACIONES	2.149

Los valores obtenidos son inferiores al umbral comúnmente aceptado de 5, e incluso se encuentran por debajo del criterio más estricto de 3, lo que indica que no existe una correlación excesiva entre las variables independientes. En consecuencia, no se detectan problemas significativos de multicolinealidad que puedan afectar la precisión o estabilidad de los coeficientes estimados.

Con base en estos resultados, se decidió mantener las tres variables independientes (Área, Baños y Habitaciones) dentro del modelo de regresión lineal múltiple, ya que cada una aporta información relevante para explicar el comportamiento del precio de las viviendas y ninguna presenta evidencia de redundancia estadística que justifique su exclusión.

Por lo tanto, se concluye que el modelo cumple satisfactoriamente con el supuesto de ausencia de multicolinealidad, permitiendo obtener estimaciones confiables e interpretables sobre la influencia de las características físicas de las viviendas en su precio de venta.

1.14 Propuesta del modelo de regresión

Con el propósito de explicar el comportamiento del precio de las viviendas en Toluca, se propuso un modelo de regresión lineal múltiple, el cual permite analizar de manera simultánea el efecto de varias variables independientes sobre una variable dependiente cuantitativa. Este tipo de modelo es adecuado cuando se busca cuantificar la contribución de diversos factores al comportamiento de una variable de interés y realizar estimaciones con base en datos observados.

La variable dependiente del modelo corresponde al precio de la vivienda, mientras que las variables independientes seleccionadas fueron Área, Baños y Habitaciones. Estas variables fueron elegidas por su relevancia dentro del mercado inmobiliario y porque representan características físicas de los inmuebles que, de acuerdo con la literatura y el comportamiento esperado del mercado, influyen directamente en su valor comercial. Asimismo, el análisis de multicolinealidad mostró que las variables presentan valores de VIF inferiores a 5, lo que justifica su inclusión conjunta en el modelo sin generar problemas de redundancia estadística.

La estructura general del modelo propuesto es la siguiente:

[

$$\text{Precio} = \beta_0 + \beta_1(\text{Área}) + \beta_2(\text{Baños}) + \beta_3(\text{Habitaciones}) + \epsilon$$

]

donde:

- Precio: variable dependiente.
- β_0 : intercepto o constante del modelo.
- β_1 , β_2 y β_3 : coeficientes de regresión que representan el efecto de cada variable independiente sobre el precio.
- ϵ : término de error aleatorio, que representa la variabilidad no explicada por el modelo.

La estimación de este modelo permite evaluar la influencia individual de cada característica física de la vivienda sobre su precio, así como determinar la capacidad conjunta de las variables independientes para explicar la variabilidad observada en el mercado inmobiliario de Toluca. Posteriormente, el modelo es sometido a pruebas de significancia y al análisis de sus supuestos estadísticos para verificar su validez y capacidad predictiva.

Esta redacción es consistente con el análisis que realizaste y deja preparada la siguiente sección, donde normalmente se presentan los coeficientes estimados, el R^2 , la prueba F (ANOVA) y la interpretación del modelo.

1.15 Evaluación de supuestos

Para garantizar la validez del modelo de regresión lineal múltiple, se evaluó el cumplimiento de los principales supuestos estadísticos: normalidad de los residuos, homocedasticidad, ausencia de multicolinealidad y significancia global del modelo.

En primer lugar, la normalidad de los residuos se verificó mediante la prueba de Shapiro-Wilk, obteniéndose un valor de $p = 0.7909$. Dado que este valor es mayor al nivel de significancia de 0.05, no se rechaza la hipótesis nula de normalidad, por lo que se concluye que los residuos del modelo presentan una distribución aproximadamente normal. Este resultado respalda la validez de las inferencias realizadas a partir del modelo.

Posteriormente, se evaluó el supuesto de homocedasticidad mediante la prueba de Breusch-Pagan, obteniéndose un valor de $p = 0.1466$. Al ser superior a 0.05, no existe evidencia estadística suficiente para afirmar la presencia de heterocedasticidad. En consecuencia, puede considerarse que la varianza de los residuos permanece constante a lo largo de los valores estimados, cumpliéndose este supuesto del modelo.

Asimismo, la evaluación de la multicolinealidad mediante el Factor de Inflación de la Varianza (VIF) mostró valores inferiores a 5 para todas las variables independientes (Área = 1.864, Baños = 1.628 y Habitaciones = 2.149), indicando que no existe una correlación excesiva entre ellas y que los coeficientes estimados son estables e interpretables.

Finalmente, la significancia global del modelo se comprobó mediante el análisis de varianza (ANOVA), obteniéndose un valor de significancia inferior a 0.05, lo que indica que el conjunto de variables independientes explica de manera significativa la variabilidad del precio de las viviendas. Además, el coeficiente de determinación (R^2) mostró que el modelo explica una proporción

importante de la variación observada en la variable dependiente, evidenciando una adecuada capacidad explicativa.

En conjunto, los resultados obtenidos permiten concluir que el modelo de regresión lineal múltiple cumple satisfactoriamente con los principales supuestos estadísticos. Por ello, las estimaciones realizadas son confiables y pueden utilizarse para interpretar la influencia del área de construcción, el número de baños y la cantidad de habitaciones sobre el precio de las viviendas en Toluca.

1.16 Análisis de capacidad predictiva

El modelo de regresión lineal múltiple desarrollado en este estudio presenta una capacidad predictiva adecuada para estimar el precio de las viviendas a partir de las variables Área, Baños y Habitaciones. Los resultados obtenidos muestran que el modelo es estadísticamente significativo y explica una proporción importante de la variabilidad observada en los precios, lo que lo convierte en una herramienta útil para realizar estimaciones dentro del contexto analizado.

La capacidad predictiva del modelo es especialmente confiable cuando se utiliza en escenarios de interpolación, es decir, al estimar el precio de viviendas cuyas características se encuentran dentro del rango de valores observado en la base de datos. En estas condiciones, las predicciones se realizan sobre información similar a la empleada para ajustar el modelo, por lo que los resultados presentan un mayor nivel de precisión y confiabilidad.

Por el contrario, el uso del modelo en escenarios de extrapolación, donde las características de la vivienda se encuentran fuera de los rangos analizados (por ejemplo, inmuebles con superficies considerablemente mayores o menores a las observadas), debe realizarse con precaución. En estos casos, las relaciones identificadas por el modelo podrían no mantenerse, disminuyendo la precisión de las estimaciones y aumentando la incertidumbre de los resultados.

Asimismo, es importante reconocer que el modelo considera únicamente variables relacionadas con las características físicas de las viviendas. Factores relevantes como la ubicación específica, la antigüedad del inmueble, el estado de conservación, los servicios disponibles, la seguridad de la zona y las condiciones económicas del mercado inmobiliario no fueron incluidos en el análisis. En consecuencia, parte de la variabilidad del precio permanece sin explicar, lo que representa una limitación del modelo.

En conclusión, el modelo posee una buena capacidad para estimar el precio de viviendas con características similares a las incluidas en la muestra y constituye una herramienta de apoyo para el análisis del mercado inmobiliario. Sin embargo, sus predicciones deben interpretarse dentro del contexto de los datos utilizados y considerando las variables que no fueron incorporadas en el modelo.

Discusión de resultados

Los resultados obtenidos en esta investigación permiten responder al planteamiento inicial, el cual consistió en analizar la influencia de las características físicas de las viviendas sobre su precio de venta en el municipio de Toluca. El modelo de regresión lineal múltiple evidenció que las variables Área, Baños y Habitaciones presentan una relación significativa con el precio de los inmuebles, confirmando que estas características contribuyen de manera importante a explicar su valor de mercado.

Desde el punto de vista estadístico, el modelo mostró un ajuste adecuado, ya que el análisis de varianza (ANOVA) indicó que el conjunto de variables independientes explica de forma significativa la variación del precio de las viviendas. Asimismo, el coeficiente de determinación (R^2) evidenció que el modelo posee una capacidad explicativa importante, lo que confirma que las variables seleccionadas representan factores relevantes dentro del mercado inmobiliario analizado.

En cuanto a la validación de los supuestos, los resultados fueron consistentes con los requerimientos de la regresión lineal múltiple. La prueba de Shapiro-Wilk indicó que los residuos presentan una distribución aproximadamente normal, mientras que la prueba de Breusch-Pagan mostró ausencia de heterocedasticidad. De igual manera, los valores del Factor de Inflación de la Varianza (VIF) fueron inferiores a los límites recomendados, lo que confirma que no existe un problema significativo de multicolinealidad entre las variables independientes. Estos resultados incrementan la confiabilidad de las estimaciones y permiten interpretar los coeficientes del modelo con mayor certeza.

No obstante, también se identifican algunas limitaciones. El modelo únicamente incorpora variables relacionadas con las características físicas de las viviendas, dejando fuera otros factores que influyen en el precio, como la ubicación específica, la antigüedad del inmueble, el nivel socioeconómico de la zona, la disponibilidad de servicios y las condiciones del mercado en el momento de la venta. Esto implica que, aunque el modelo ofrece estimaciones confiables dentro del conjunto de datos analizado, aún existe una parte de la variabilidad del precio que no puede explicarse únicamente con las variables incluidas.

En términos aplicados, los hallazgos son coherentes con el comportamiento esperado del mercado inmobiliario, donde viviendas con mayor superficie, más habitaciones y un mayor número de baños suelen alcanzar precios superiores. Por ello, el modelo puede utilizarse como una herramienta de apoyo para la valuación de inmuebles y para la toma de decisiones de compradores, vendedores e inversionistas, siempre que las predicciones se realicen dentro del rango de características representado por la muestra.

En conclusión, los resultados obtenidos son consistentes con el planteamiento inicial de la investigación y demuestran que la regresión lineal múltiple constituye una metodología adecuada para analizar y predecir el precio de las viviendas a partir de sus características físicas. Asimismo, el cumplimiento de los supuestos estadísticos fortalece la validez de las conclusiones y proporciona evidencia suficiente para considerar el modelo como una herramienta útil dentro del contexto del mercado inmobiliario de Toluca.

En este contexto, se sugiere considerar la siguiente cuestión orientadora:

¿En qué medida las decisiones metodológicas adoptadas influyen en la capacidad explicativa y predictiva del modelo propuesto?

Conclusiones

El presente estudio permitió analizar la relación entre las características físicas de las viviendas y su precio de venta mediante la aplicación de un modelo de regresión lineal múltiple. Los resultados obtenidos demuestran que las variables Área, Baños y Habitaciones constituyen predictores relevantes del precio de las viviendas, cumpliendo con el objetivo de identificar los factores que influyen en su valor dentro del mercado inmobiliario de Toluca.

La evaluación de los supuestos estadísticos confirmó que el modelo presenta condiciones adecuadas para su interpretación y utilización. La ausencia de problemas significativos de multicolinealidad, la normalidad de los residuos y la homocedasticidad evidencian que las estimaciones obtenidas son confiables y que el modelo cumple con los requisitos fundamentales de la regresión lineal múltiple. Asimismo, la prueba ANOVA confirmó la significancia global del modelo, indicando que las variables independientes explican de manera conjunta una parte importante de la variabilidad observada en el precio de las viviendas.

Desde una perspectiva práctica, el modelo desarrollado puede emplearse como una herramienta de apoyo para la estimación del valor de inmuebles con características similares a las incluidas en la muestra, contribuyendo a la toma de decisiones de compradores, vendedores, desarrolladores e inversionistas. No obstante, sus predicciones deben limitarse a escenarios de interpolación, ya que

la extrapolación hacia viviendas con características fuera del rango observado puede disminuir la precisión de las estimaciones.

Entre las principales limitaciones del estudio destaca la exclusión de variables que también influyen en el valor de una vivienda, como la ubicación específica, la antigüedad del inmueble, el estado de conservación, el acceso a servicios y las condiciones del mercado inmobiliario. La incorporación de estos factores en investigaciones futuras permitiría incrementar la capacidad explicativa y predictiva del modelo.

En conclusión, la aplicación de la regresión lineal múltiple permitió comprender el comportamiento del precio de las viviendas a partir de sus características físicas y demostró la utilidad de las técnicas estadísticas para analizar fenómenos económicos reales. Los resultados obtenidos son coherentes con el planteamiento inicial y respaldan el uso de modelos de regresión como una herramienta eficaz para el análisis y la predicción dentro del sector inmobiliario.

Estas conclusiones son consistentes con el resto del documento y tienen un nivel adecuado para un reporte universitario de Gestión Empresarial o Estadística.

Alcance metodológico

El enfoque adoptado se fundamenta en la transformación de variables categóricas mediante el ordenamiento de sus medias respecto a la variable dependiente. Esta aproximación permite integrar información categórica dentro de un marco de modelación lineal; sin embargo, implica supuestos sobre la estructura ordinal de las categorías que deben ser analizados críticamente.

En este sentido, la codificación basada en medias debe entenderse como una estrategia con fines formativos, cuya validez depende del comportamiento empírico de los datos y de la coherencia analítica de su aplicación. Por lo tanto, los resultados obtenidos deben interpretarse considerando las limitaciones inherentes a esta decisión metodológica, así como su pertinencia dentro del contexto del estudio.

Se recopiló información de viviendas en Toluca, México, con el objetivo de analizar los factores que influyen en el precio de las propiedades. Los datos fueron obtenidos mediante web scraping utilizando BeautifulSoup, permitiendo realizar análisis estadísticos y modelos de predicción.

```
import pandas as pd
link= "https://raw.githubusercontent.com/cortespaolalejandra-
dotcom/EstadisticaVerano2026/refs/heads/main/Casa%20Toluca/Casa_toluca.csv"
df=pd.read_csv(link)
df
```

	Unnamed: 0.2	Unnamed: 0	Unnamed: 0.1	Ubicación	Area	Baños	Habitaciones	Precio
0	0	0	0	Casa en Venta Los Serrados\r\n, Toluca De Lerdo...	105.0	2.0	3.0	130000.0
1	1	1	1	Casa en Venta Tierra Y Libertad #114\r\n, Tolu...	115.0	2.0	3.0	50800.0
2	2	2	2	Casa en Venta Toluca De Lerdo, México	700.0	3.0	3.0	325000.0
3	3	3	3	Casa en Venta Granjas, Toluca De Lerdo	390.0	3.0	4.0	275000.0
4	4	4	4	Casa en Venta Toluca De Lerdo, México	300.0	4.0	3.0	215000.0
...	...	...	...	...	...	...	...	...
1999	1999	1999	1999	Casa en Venta Toluca De Lerdo, México	190.0	NaN	NaN	60775.0
2000	2000	2000	2000	Casa en Venta Toluca De Lerdo, México	92.0	NaN	NaN	62330.0
2001	2001	2001	2001	Casa en Venta Toluca De Lerdo, México	66.0	NaN	NaN	47500.0

	Unnamed: 0.2	Unnamed: 0	Unnamed: 0.1	Ubicación	Area	Baños	Habitaciones	Precio
2002	2002	2002	2002	Casa en Venta Toluca De Lerdo, México	42.0	NaN	NaN	13695.0
2003	2003	2003	2003	Casa en Venta Toluca De Lerdo, México	NaN	NaN	NaN	270250.0

2004 rows × 8 columns

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2004 entries, 0 to 2003
Data columns (total 8 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Unnamed: 0.2    2004 non-null  int64
1   Unnamed: 0      2004 non-null  int64
2   Unnamed: 0.1    2004 non-null  int64
3   Ubicación       2004 non-null  object
4   Area            1721 non-null  float64
5   Baños           1950 non-null  float64
6   Habitaciones    1931 non-null  float64
7   Precio          1999 non-null  float64
dtypes: float64(4), int64(3), object(1)
memory usage: 125.4+ KB
```

```
df.dropna(inplace = True)
```

```
df.describe()
```

	Unnamed: 0.2	Unnamed: 0	Unnamed: 0.1	Area	Baños	Habitaciones	
count	1658.000000	1658.000000	1658.000000	1658.000000	1658.000000	1658.000000	1.6580
mean	970.604946	970.604946	970.604946	227.958384	2.528347	3.263571	1.5903
std	590.233641	590.233641	590.233641	337.590491	3.311906	1.520692	4.1950
min	0.000000	0.000000	0.000000	10.000000	1.000000	1.000000	1.0653
25%	454.250000	454.250000	454.250000	113.250000	2.000000	3.000000	4.7872
50%	935.000000	935.000000	935.000000	163.000000	2.000000	3.000000	8.4625
75%	1513.750000	1513.750000	1513.750000	250.000000	3.000000	3.000000	1.5000
max	1982.000000	1982.000000	1982.000000	11111.000000	124.000000	40.000000	1.0000

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1658 entries, 0 to 1982
Data columns (total 8 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Unnamed: 0.2    1658 non-null  int64
1   Unnamed: 0      1658 non-null  int64
2   Unnamed: 0.1    1658 non-null  int64
3   Ubicación       1658 non-null  object
4   Area            1111 non-null  float64
5   Baños           124 non-null   float64
6   Habitaciones    40 non-null    float64
7   Precio          1658 non-null  float64
dtypes: float64(4), int64(3), object(1)
memory usage: 125.4+ KB
```

```

0  Unnamed: 0.2  1658 non-null  int64
1  Unnamed: 0    1658 non-null  int64
2  Unnamed: 0.1  1658 non-null  int64
3  Ubicación     1658 non-null  object
4  Area          1658 non-null  float64
5  Baños         1658 non-null  float64
6  Habitaciones  1658 non-null  float64
7  Precio       1658 non-null  float64

```

dtypes: float64(4), int64(3), object(1)

memory usage: 116.6+ KB

```
df.describe()
```

	Unnamed: 0.2	Unnamed: 0	Unnamed: 0.1	Area	Baños	Habitaciones	
count	1658.000000	1658.000000	1658.000000	1658.000000	1658.000000	1658.000000	1.6580
mean	970.604946	970.604946	970.604946	227.958384	2.528347	3.263571	1.5903
std	590.233641	590.233641	590.233641	337.590491	3.311906	1.520692	4.1950
min	0.000000	0.000000	0.000000	10.000000	1.000000	1.000000	1.0653
25%	454.250000	454.250000	454.250000	113.250000	2.000000	3.000000	4.7872
50%	935.000000	935.000000	935.000000	163.000000	2.000000	3.000000	8.4624
75%	1513.750000	1513.750000	1513.750000	250.000000	3.000000	3.000000	1.5000
max	1982.000000	1982.000000	1982.000000	11111.000000	124.000000	40.000000	1.0000

```
print(df['Ubicación'].unique())
```

```

['Casa en Venta Los Serrados\r\n, Toluca De Lerdo, México'
'Casa en Venta Tierra Y Libertad #114\r\n, Toluca De Lerdo, México'
'Casa en Venta Toluca De Lerdo, México' ...
'Casa en Venta Jose María Arteaga #00, 00\r\n, Toluca De Lerdo, México'
'Casa en Venta Tomas Alva Edison #00, 00\r\n, Toluca De Lerdo, México'
'Casa en Venta Valladolid ## 101, 19 A\r\n, Toluca De Lerdo, México']

```

```
df.drop(columns=["Unnamed: 0.2", "Unnamed: 0", "Unnamed: 0.1",
                "Ubicación"],inplace = True)
```


#Mapa de calor

```

import seaborn as sns
import matplotlib.pyplot as plt

correlation_matrix = df.corr(numeric_only=True)
plt.figure(figsize=(30, 18))
sns.heatmap(correlation_matrix,
            annot=True,
            cmap='coolwarm',
            fmt=".4f",
            square=True,
            center=0,
            cbar_kws={"shrink": .8})
plt.title('Mapa de Calor de la Matriz de Correlación')
plt.show()

```



#Análisis de multicolinealidad

```
df=df[["Area", "Baños", "Habitaciones", "Precio"]]
df
```

	Area	Baños	Habitaciones	Precio
0	105.0	2.0	3.0	130000.0
1	115.0	2.0	3.0	50800.0
2	700.0	3.0	3.0	325000.0
3	390.0	3.0	4.0	275000.0
4	300.0	4.0	3.0	215000.0
...	...	...	...	...
1976	60.0	1.0	2.0	30000.0
1977	120.0	2.0	2.0	35000.0
1980	294.0	3.0	3.0	100000.0
1981	353.0	5.0	5.0	105000.0
1982	624.0	3.0	4.0	210000.0

1658 rows × 4 columns

```
from statsmodels.stats.outliers_influence import variance_inflation_factor
```

```
# Assuming df contains only the independent variables we want to check
X = df
```

```
# Calculate VIF for each feature
vif_data = pd.DataFrame()
```

```
vif_data["feature"] = X.columns
vif_data["VIF"] = [variance_inflation_factor(X.values, i) for i in
                    range(len(X.columns))]

print("VIF Results:")
print(vif_data)
```


VIF Results:

	feature	VIF
0	Area	1.864068
1	Baños	1.627876
2	Habitaciones	2.149275
3	Precio	1.431271

#Mapa de calor

```
import seaborn as sns
import matplotlib.pyplot as plt

correlation_matrix = df.corr()
plt.figure(figsize=(30, 18))
sns.heatmap(correlation_matrix,
            annot=True,
            cmap='coolwarm',
            fmt=".4f",
            square=True,
            center=0,
            cbar_kws={"shrink": .8})
plt.title('Mapa de Calor de la Matriz de Correlación')
plt.show()
```



#Establecer variables

```
x=df[["Area", "Baños", "Habitaciones"]]
```

```
y=df["Precio"]
```

```
#6. Obtenga la recta de regresión ajustada y grafíquelo sobre el  
# gráfico de dispersión
```

```
import statsmodels.api as sm  
x_constante = sm.add_constant(x)  
modelo = sm.OLS(y, x_constante).fit()  
y_calculada = modelo.predict(x_constante)
```

```
modelo.params
```

	0	
const	-84422.595455	
Area	484.837593	
Baños	7224.442174	
Habitaciones	35134.640984	

```
dtype: float64
```

```
# @title  
# 2. Realice un diagrama de dispersión para estos datos.  
import matplotlib.pyplot as plt  
  
# --- Configuración general del gráfico ---  
plt.figure(  
    figsize=(6, 4),    # tamaño de la figura (ancho, alto) en pulgadas  
    dpi=120            # resolución del gráfico  
)  
  
# --- Gráfico de dispersión ---  
plt.scatter(  
    y, y_calculada,  
    marker="o",        # forma  
    color='blue',      # color de los puntos  
    edgecolor='Blue',  # borde de los puntos  
    alpha=0.1,         # transparencia  
    s=50,              # tamaño de los puntos  
    label='Precio' # etiqueta para la leyenda  
)  
  
# --- Gráfico de línea ---  
plt.plot(  
    y_calculada, y_calculada,  
    color='black',    # color de la línea  
    linewidth=1,      # grosor de la línea  
    linestyle='--',   # estilo de línea  
    marker='o',       # marcador en cada punto  
    markersize=0,     # tamaño del marcador  
    markerfacecolor='white',  
    markeredgecolor='black',  
    label='Recta de regresión'  
)  
  
# --- Título ---  
plt.title(  
    'Gráfico de dispersión entre los precios reales e hipotéticos',  
    fontsize=14,  
    fontweight='bold'
```

```

)

# --- Etiquetas de Los ejes ---
plt.xlabel(
    y.name, # Using the actual name of the 'y' Series
    fontsize=12
)

plt.ylabel(
    'Precio Hipotetico',
    fontsize=12
)

# --- Fuente de Los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de Los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False) # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)

# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)


# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    'Fuente: Datos de factores de rendimiento estudiantil.',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico de dispersión",
    bbox_inches='tight'
)

plt.show()

```

Gráfico de dispersión entre los precios reales e hipotéticos



Fuente: Datos de factores de rendimiento estudiantil.

5. *r2* Calcule el coeficiente de determinación e interprete el resultado.

```
from sklearn.metrics import r2_score # recomendada
r2 = r2_score(y, y_calculada)
print(f'Coeficiente de determinación: {r2: 0.2%}\n')
```

Coeficiente de determinación: 20.79%

7. *Obtenga un intervalo de confianza del 95% para la pendiente de la recta de*

regresión ajustada (b1)

intervalo de confianza = 1 - alpha

```
modelo.conf_int(alpha = 0.05)
```

	0	1
const	-127492.520372	-41352.670538
Area	429.108235	540.566951
Baños	1663.688886	12785.195463
Habitaciones	22585.678895	47683.603073

```
residuales=modelo.resid
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns
```

Prueba de Shapiro-Wilk-----

```
stat, valor_p_sh = shapiro(residuales)
print(f"valor-p (Shapiro) = {valor_p_sh}")
```



```
# Visualización: Q-Q plot
sm.qqplot(residuales, line='s')
plt.title("Q-Q plot de residuos")
plt.show()
```



```
# Histograma
```

```
sns.histplot(residuales, kde=True)  
plt.title("Histograma de residuos")  
plt.show()
```

valor-p (Shapiro) = $5.015787239270482 \times 10^{-64}$



```
# 10. Realice la prueba de Breusch-Pagan para los residuales  
# y comente el resultado.
```

```

# Test de Breusch-Pagan
# H0: No hay heterocedasticidad (dispersión es igual en toda la recta)
# H1: Hay Heterocedasticidad (dispersión distinta a lo largo de la recta)
# alpha = 0.05

from statsmodels.stats.api import het_breuschpagan
_, valor_p_bp, _, _ = het_breuschpagan(residuales, x_constante)
print(f'valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')

valor_p de Breusch-Pagan: 0.0000

# 12. Realice una tabla ANOVA e interprete el resultado.

# test de ANOVA (Analysis of Variance)
# H0: beta_1 = 0 (No hay correlación)
# H1: beta_1 ≠ 0 (Sí hay correlación)

from statsmodels.formula.api import ols
# Y ~ X
# Correcting the formula to use only one '~' and specifying the dependent and
# independent variables.
# Based on the previous linear regression, 'Precio' is the dependent variable
# (y)
# and 'Area', 'Baños', 'Habitaciones' are the independent variables (x).
modelo_lineal = ols('Precio ~ Area + Baños + Habitaciones', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal)
tabla_anova

```

	df	sum_sq	mean_sq	F	PR(>F)
Area	1.0	5.463166e+13	5.463166e+13	391.221066	2.496513e-78
Baños	1.0	1.790522e+12	1.790522e+12	12.822050	3.524586e-04
Habitaciones	1.0	4.211236e+12	4.211236e+12	30.156952	4.605058e-08
Residual	1654.0	2.309711e+14	1.396440e+11	NaN	NaN