

La cadena de gimnasios FitLife ha recopilado información de cientos de socios con el objetivo de comprender mejor qué factores influyen en el gasto calórico durante una sesión de entrenamiento.

```
import pandas as pd
link= "https://raw.githubusercontent.com/cortespaolalejandra-
dotcom/EstadisticaVerano2026/refs/heads/main/GYMMEMBERS/gym_members_exercise_tracking.csv"
df=pd.read_csv(link)
df
```

	Age	Gender	Weight (kg)	Height (m)	Max_BPM	Avg_BPM	Resting_BPM	Session_Duration (hours)	Calories_Burned
0	56	Male	88.3	1.71	180	157	60	1.69	1313.0
1	46	Female	74.9	1.53	179	151	66	1.30	883.0
2	32	Female	68.1	1.66	167	122	54	1.11	677.0
3	25	Male	53.2	1.70	190	164	56	0.59	532.0
4	38	Male	46.1	1.79	188	158	68	0.64	556.0
...	...	...	...	...	...	...	...	...	...
968	24	Male	87.1	1.74	187	158	67	1.57	1364.0
969	25	Male	66.6	1.61	184	166	56	1.38	1260.0
970	59	Female	60.4	1.76	194	120	53	1.72	929.0
971	32	Male	126.4	1.83	198	146	62	1.10	883.0
972	46	Male	88.7	1.63	166	146	66	0.75	542.0

973 rows × 15 columns

```
df.rename(
    columns={
        "Session_Duration (hours)": "duracion_sesion_hrs",
        "Calories_Burned": "calorias_quemadas",
        "Gender": "genero",
        "Workout_Type": "tipo_entrenamiento",
        "Experience_Level": "nivel_experiencia",
        "Workout_Frequency (days/week)": "frecuencia_dias",
        "Age": "edad"
    },
    inplace=True
)
df
```

	edad	genero	Weight (kg)	Height (m)	Max_BPM	Avg_BPM	Resting_BPM	duracion_sesion_hrs	calorias_quemadas
0	56	Male	88.3	1.71	180	157	60	1.69	1313.0
1	46	Female	74.9	1.53	179	151	66	1.30	883.0
2	32	Female	68.1	1.66	167	122	54	1.11	677.0
3	25	Male	53.2	1.70	190	164	56	0.59	532.0
4	38	Male	46.1	1.79	188	158	68	0.64	556.0
...	...	...	...	...	...	...	...	...	...
968	24	Male	87.1	1.74	187	158	67	1.57	1364.0
969	25	Male	66.6	1.61	184	166	56	1.38	1260.0
970	59	Female	60.4	1.76	194	120	53	1.72	929.0
971	32	Male	126.4	1.83	198	146	62	1.10	883.0
972	46	Male	88.7	1.63	166	146	66	0.75	542.0

973 rows × 15 columns

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 973 entries, 0 to 972
Data columns (total 15 columns):
```

#	Column	Non-Null Count	Dtype
0	edad	973 non-null	int64
1	genero	973 non-null	object
2	Weight (kg)	973 non-null	float64
3	Height (m)	973 non-null	float64
4	Max_BPM	973 non-null	int64
5	Avg_BPM	973 non-null	int64
6	Resting_BPM	973 non-null	int64
7	duracion_sesion_hrs	973 non-null	float64
8	calorias_quemadas	973 non-null	float64
9	tipo_entrenamiento	973 non-null	object
10	Fat_Percentage	973 non-null	float64
11	Water_Intake (liters)	973 non-null	float64
12	frecuencia_dias	973 non-null	int64
13	nivel_experiencia	973 non-null	int64
14	BMI	973 non-null	float64

dtypes: float64(7), int64(6), object(2)
memory usage: 114.2+ KB

```

from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
tukey = pairwise_tukeyhsd(endog=df['calorias_quemadas'], groups=df['genero'],
                           alpha=nivel_de_significancia)

# Mostrar Los resultados
print(tukey)

# Gráfico de Las diferencias entre grupos
tukey.plot_simultaneous(ylabel="Grupos", xlabel="Medias")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")


#Guardar imagen
plt.savefig(
    "Dispersión",
    bbox_inches="tight"
)

```

```

Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1 group2 meandiff p-adj lower upper reject
-----
Female Male 82.2071 0.0 48.2331 116.181 True
-----

```



Ordenamos de mayor a menor los terminos, "Female" y "Male".

```

df["genero"]=df["genero"].map({"Female":0,"Male":1})
df

```

	edad	genero	Weight (kg)	Height (m)	Max_BPM	Avg_BPM	Resting_BPM	duracion_sesion_hrs	calorias_quemadas
0	56	1	88.3	1.71	180	157	60	1.69	1313.0
1	46	0	74.9	1.53	179	151	66	1.30	883.0
2	32	0	68.1	1.66	167	122	54	1.11	677.0
3	25	1	53.2	1.70	190	164	56	0.59	532.0
4	38	1	46.1	1.79	188	158	68	0.64	556.0
...	...	...	...	...	...	...	...	...	...
968	24	1	87.1	1.74	187	158	67	1.57	1364.0
969	25	1	66.6	1.61	184	166	56	1.38	1260.0
970	59	0	60.4	1.76	194	120	53	1.72	929.0
971	32	1	126.4	1.83	198	146	62	1.10	883.0
972	46	1	88.7	1.63	166	146	66	0.75	542.0

973 rows × 15 columns

```

from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
tukey = pairwise_tukeyhsd(endog=df['calorias_quemadas'],
                           groups=df['tipo_entrenamiento'], alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="Grupos", xlabel="Medias")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")


# Guardar imagen
plt.savefig(
    "Dispersión",
    bbox_inches="tight"
)

```

```

Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1 group2 meandiff p-adj lower upper reject
-----
Cardio HIIT 41.2917 0.3523 -23.1974 105.7809 False
Cardio Strength 26.1839 0.6973 -35.7784 88.1463 False
Cardio Yoga 18.6746 0.8721 -44.5002 81.8494 False
HIIT Strength -15.1078 0.9306 -79.4226 49.2071 False
HIIT Yoga -22.6171 0.8107 -88.1009 42.8666 False
Strength Yoga -7.5094 0.99 -70.5062 55.4875 False
=====

```



Ordenamos de menor a mayor:

- Cardio
- Yoga
- Strength
- HIIT


```
df["tipo_entrenamiento"]=df["tipo_entrenamiento"].map({"Cardio":0,"Yoga":1,"Strength":2,"HIIT":3})
df
```

	edad	genero	Weight (kg)	Height (m)	Max_BPM	Avg_BPM	Resting_BPM	duracion_sesion_hrs	calorias_quemadas
0	56	1	88.3	1.71	180	157	60	1.69	1313.0
1	46	0	74.9	1.53	179	151	66	1.30	883.0
2	32	0	68.1	1.66	167	122	54	1.11	677.0
3	25	1	53.2	1.70	190	164	56	0.59	532.0
4	38	1	46.1	1.79	188	158	68	0.64	556.0
...	...	...	...	...	...	...	...	...	...
968	24	1	87.1	1.74	187	158	67	1.57	1364.0
969	25	1	66.6	1.61	184	166	56	1.38	1260.0
970	59	0	60.4	1.76	194	120	53	1.72	929.0
971	32	1	126.4	1.83	198	146	62	1.10	883.0
972	46	1	88.7	1.63	166	146	66	0.75	542.0

973 rows × 15 columns

```
import seaborn as sns
import matplotlib.pyplot as plt

correlation_matrix = df.corr()
plt.figure(figsize=(30, 18))
sns.heatmap(correlation_matrix,
            annot=True,
            cmap='coolwarm',
            fmt=".4f",
            square=True,
            center=0,
            cbar_kws={"shrink": .8})
plt.title('Mapa de Calor de la Matriz de Correlación')
plt.show()
```



Quitamos las que son muy intrusivas o personales como:


peso,altura,max_bpm,promedio_bpm,reposo_bpm,porcentaje_grasa,agua,imc

```
df=df[["duracion_sesion_hrs","nivel_experiencia","frecuencia_dias","genero","edad","calorias_quemadas"]]  
df
```

	duracion_sesion_hrs	nivel_experiencia	frecuencia_dias	genero	edad	calorias_quemadas
0	1.69	3	4	1	56	1313.0
1	1.30	2	4	0	46	883.0
2	1.11	2	4	0	32	677.0
3	0.59	1	3	1	25	532.0
4	0.64	1	3	1	38	556.0
...	...	...	...	...	...	...
968	1.57	3	4	1	24	1364.0
969	1.38	1	2	1	25	1260.0
970	1.72	3	5	0	59	929.0
971	1.10	2	3	1	32	883.0
972	0.75	1	2	1	46	542.0

973 rows × 6 columns

```
import seaborn as sns  
import matplotlib.pyplot as plt  
  
correlation_matrix = df.corr()  
plt.figure(figsize=(30, 18))  
sns.heatmap(correlation_matrix,  
            annot=True,  
            cmap='coolwarm',  
            fmt=".4f",  
            square=True,  
            center=0,  
            cbar_kws={"shrink": .8})  
plt.title('Mapa de Calor de la Matriz de Correlación')  
plt.show()
```



```
x=df[["duracion_sesion_hrs", "frecuencia_dias", "genero", "edad"]]
y=df["calorias_quemadas"]
```

```
import statsmodels.api as sm
x_constante=sm.add_constant(x)
modelo=sm.OLS(y,x_constante).fit()
y_calculada=modelo.predict(x_constante)
modelo.params

from matplotlib.lines import lineStyles
import matplotlib.pyplot as plt
#configuración general
plt.figure(
    figsize=(6,4), #tamaño (ancho, alto)
    dpi=100 #resolución
)
#Gráfico de dispersión
plt.scatter(
    y, y_calculada,
    marker="o",
    color="pink",
    edgecolor="purple", #color de borde
    alpha=0.9, #transparencia
    s=60, #tamaño de punto
    label="calorias quemadas" #etiqueta
)

plt.plot(
    y_calculada,y_calculada,
    marker="o",
    color="blue",
    linewidth=2.2,
    linestyle="--",
    markersize=5,
    markerfacecolor="white",
    markeredgcolor="black",
    label="recta de regresión"
)

#Título
plt.title(
    "Gráfico de dispersión",
    fontsize=12, #tamaño de fuente
    fontweight="bold" #bold:negritas
)
#Etiquetas eje x
plt.xlabel(
    "calorias teóricas",
```

```

        fontsize=10,
    )
    #Etiqueta eje y
    plt.ylabel(
        "calorias reales",
        fontsize=10
    )
    #tamaño de los ticks
    plt.xticks(fontsize=10)
    plt.yticks(fontsize=10)

    #Márgenes
    plt.margins(x=0.05,y=0.05)
    plt.gca().spines[["top", "right"]].set_visible(False)

    plt.grid(
        visible=True,
        linestyle="--",
        linewidth=0.7, #ancho de Linea
        alpha=0.5, #transparencia
        color="green"
    )

    #Leyenda
    plt.legend(
        fontsize=10,
        loc="best",
        frameon=False
        #bbox_to_anchor=(0.5,-0.15)
    )

    #Guardar imagen
    plt.savefig(
        "Dispersión",
        bbox_inches="tight"
    )

    from sklearn.metrics import r2_score
    r2=r2_score(y,y_calculada)
    print(f"Coefficiente de determinación: {r2:0.2%}\n")

```

El modelo explica a un 87.08% la variación de la variable dependiente. Esta justificando al 87.08% la variabilidad

```

#Obtenga un intervalo de confianza del 95% para la pendiente de la recta de
#regresión ajustada ( b1 )
modelo.conf_int(alpha = 0.05)

```

```
residuales=modelo.resid
```

```

#Histograma y Q-Q plot
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

```

```

# Visualización: Q-Q plot
sm.qqplot(residuales, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

```

```

# Histograma
sns.histplot(residuales, kde=True)
plt.title("Histograma de residuos")
plt.show()

```

```

#Test de Breusch-Pagan
from statsmodels.stats.api import het_breuschpagan
estadistico_1, valor_p_1, estadistico_2, valor_p_2 =
    het_breuschpagan(residuales, x_constante)
print(f"valor_p:{valor_p_1:0.4f}")
# Ho: No hay heterocedasticidad (varianza uniforme)
# H1: Hay heterocedasticidad (varianza no uniforme)
# Como el valor p es mayor a el nivel de significancia, entonces la Ho es
verdadera
# No hay heterocedasticidad, por lo tanto, hay homocedasticidad o la varianza
es uniforme

```

Como el valor p es menor al nivel de significancia, entonces H0 es falsa, por lo tanto, hay heterocedasticidad y la varianza no es uniforme.

```
df.describe()
```

```
#Realice una tabla ANOVA e interprete el resultado.
```

```
from statsmodels.formula.api import ols
```

```
# y ~ x
```

```
modelo_lineal=ols("calorias_quemadas~duracion_sesion_hrs+frecuencia_dias+genero+edad",  
                  data=df).fit()
```

```
tabla_anova=sm.stats.anova_lm(modelo_lineal)
```

```
tabla_anova
```

- Duración=0.0000 ---- > SÍ HAY CORRELACIÓN
- Frecuencia=0.3185 ---- > NO HAY CORRELACIÓN
- Genero=0.0000 ---- > SÍ HAY CORRELACIÓN
- Edad=0.00000 ---- > SÍ HAY CORRELACIÓN Se puede ignorar la variable que no tiene correlación, o se repite el análisis pero quitando la variable de frecuencia

```
#Realice una tabla ANOVA e interprete el resultado.
```

```
from statsmodels.formula.api import ols
```

```
# y ~ x
```

```
modelo_lineal=ols("calorias_quemadas~duracion_sesion_hrs+genero+edad",  
                  data=df).fit()
```

```
tabla_anova=sm.stats.anova_lm(modelo_lineal)
```

```
tabla_anova.round(4)
```

Todas las variables tienen correlación, el modelo es significativo.

```
df=df[["duracion_sesion_hrs", "genero", "edad", "calorias_quemadas"]]
```

```
df
```

```
#Obtenga la recta de regresión ajustada y grafíquelo sobre el gráfico de dispersión.
```

```
import statsmodels.api as sm
```

```
x_constante=sm.add_constant(x)
```

```
modelo=sm.OLS(y,x_constante).fit()
```

```
y_calculada=modelo.predict(x_constante)
```

```
modelo.params
```

```
#grafíquelo sobre el gráfico de dispersión.
```

```
from matplotlib.lines import lineStyles
```

```
import matplotlib.pyplot as plt
```

```
#configuración general
```

```
plt.figure(  
    figsize=(6,4), #tamaño (ancho, alto)  
    dpi=100 #resolución  
)
```

```
#Gráfico de dispersión
```

```
plt.scatter(  
    y, y_calculada,  
    marker="o",  
    color="purple",  
    edgecolor="pink", #color de borde  
    alpha=0.9, #transparencia  
    s=60, #tamaño de punto  
    label="calorias quemadas" #etiqueta  
)
```

```
plt.plot(  
    y_calculada,y_calculada,  
    marker="o",  
    color="blue",  
    linewidth=2.2,  
    linestyle="--",  
    markersize=5,  
    markerfacecolor="white",  
    markeredgcolor="black",  
    label="recta de regresión"  
)
```

```
#Titulo
```

```
plt.title(  
    "Gráfico de dispersión",  
    fontsize=12, #tamaño de fuente  
    fontweight="bold" #bold:negritas  
)
```

```
#Etiquetas eje x
```

```
plt.xlabel(  
    "calorias teóricas",
```



```

        fontsize=10,
    )
    #Etiqueta eje y
    plt.ylabel(
        "calorias reales",
        fontsize=10
    )
    #tamaño de los ticks
    plt.xticks(fontsize=10)
    plt.yticks(fontsize=10)

    #Márgenes
    plt.margins(x=0.05,y=0.05)
    plt.gca().spines[["top", "right"]].set_visible(False)

    plt.grid(
        visible=True,
        linestyle="--",
        linewidth=0.7, #ancho de Linea
        alpha=0.5, #transparencia
        color="black"
    )

    #Leyenda
    plt.legend(
        fontsize=10,
        loc="best",
        frameon=False
        #bbox_to_anchor=(0.5,-0.15)
    )

    #Guardar imagen
    plt.savefig(
        "Dispersión",
        bbox_inches="tight"
    )

    from sklearn.metrics import r2_score
    r2=r2_score(y,y_calculada)
    print(f"Coefficiente de determinación: {r2:0.2%}\n")

```

El modelo explica a un 87.08% la variación de la variable dependiente. Esta justificando al 87.08% la variabilidad

```

#Obtenga un intervalo de confianza del 95% para la pendiente de la recta de
#regresión ajustada ( b1 )
modelo.conf_int(alpha = 0.05)

```

```

#Histograma y Q-Q plot
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

```

```

# Visualización: Q-Q plot
sm.qqplot(residuales, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

```

```

# Histograma
sns.histplot(residuales, kde=True)
plt.title("Histograma de residuos")
plt.show()

```

```

#Test de Breusch-Pagan
from statsmodels.stats.api import het_breuschpagan
estadistico_1, valor_p_1, estadistico_2, valor_p_2 =
    het_breuschpagan(residuales, x_constante)
print(f"valor_p:{valor_p_1:0.4f}")
# Ho: No hay heterocedasticidad (varianza uniforme)
# H1: Hay heterocedasticidad (varianza no uniforme)
# Como el valor p es mayor a el nivel de significancia, entonces la Ho es
verdadera
# No hay heterocedasticidad, por lo tanto, hay homocedasticidad o la varianza
es uniforme

```

Como el valor p es menor al nivel de significancia, entonces H0 es falsa. Por lo tanto, hay heterocedasticidad y la varianza no es uniforme

```
df.describe()
```

Si el modelo no cumple con los 3 supuestos (linealidad, homocedasticidad, linealidad) se invalidan los intervalos de confianza

Modelación estadística de las calorías quemadas en usuarios de gimnasio mediante un modelo de regresión lineal múltiple.

El análisis de datos en el ámbito del acondicionamiento físico y la salud ha adquirido relevancia debido a la disponibilidad de información estructurada sobre hábitos de entrenamiento, características fisiológicas y métricas de desempeño. El presente proyecto se desarrolla a partir de un conjunto de datos de miembros de gimnasio, el cual integra variables de distinta naturaleza que permiten explorar relaciones entre factores asociados al ejercicio y resultados observables en el rendimiento físico.

En este contexto, la modelación estadística se plantea como una herramienta para identificar patrones, evaluar asociaciones y construir modelos con capacidad explicativa y predictiva. No obstante, la integración de variables categóricas y numéricas, así como las decisiones metodológicas asociadas a su tratamiento, constituyen elementos críticos que pueden influir en la interpretación de los resultados.

El presente estudio resulta relevante porque permite identificar los factores que influyen en la cantidad de calorías quemadas durante la actividad física. Mediante el análisis estadístico de variables relacionadas con las características físicas y los hábitos de entrenamiento de los usuarios, es posible construir un modelo que explique el comportamiento de la variable dependiente y contribuya a una mejor comprensión del rendimiento físico. Además, este tipo de análisis fortalece la toma de decisiones basada en datos y permite aplicar los conocimientos adquiridos sobre regresión lineal múltiple en un caso práctico.

El análisis de datos multivariados implica decisiones sobre selección, transformación e integración de variables. La coexistencia de variables categóricas y numéricas plantea interrogantes sobre su incorporación en modelos estadísticos.

El presente estudio resulta relevante porque permite identificar los factores que influyen en la cantidad de calorías quemadas durante la actividad física. Mediante el análisis estadístico de variables relacionadas con las características físicas y los hábitos de entrenamiento de los usuarios, es posible construir un modelo que explique el comportamiento de la variable dependiente y contribuya a una mejor comprensión del rendimiento físico. Además, este tipo de análisis fortalece la toma de decisiones basada en datos y permite aplicar los conocimientos adquiridos sobre regresión lineal múltiple en un caso práctico.

Desarrollar un modelo de regresión lineal múltiple que permita explicar el comportamiento de una variable dependiente seleccionada.

1. Objetivos específicos

- Seleccionar y justificar una variable dependiente.
- Evaluar variables categóricas mediante comparación de medias.
- Codificar variables categóricas con base en sus medias.

- Analizar relaciones mediante correlación.
- Evaluar multicolinealidad.
- Proponer un modelo de regresión.
- Validar supuestos.
- Analizar capacidad predictiva.

Marco analítico y desarrollo del estudio

Variable dependiente

La variable dependiente seleccionada fue `Calories_Burned`, la cual representa la cantidad de calorías quemadas por cada usuario durante su entrenamiento. Esta variable fue elegida debido a que constituye un indicador importante del rendimiento físico y permite analizar cómo diferentes características personales y hábitos de ejercicio influyen en el gasto energético.

Variables categóricas

Las variables categóricas consideradas en el estudio fueron `Gender` y `Workout_Type`, ya que representan características cualitativas de los usuarios del gimnasio. Para determinar si estas variables presentaban diferencias significativas respecto a la variable dependiente, se realizó una comparación de medias entre sus diferentes categorías antes de incorporarlas al modelo de regresión.

Codificación

Las variables categóricas fueron transformadas mediante un proceso de codificación basado en el orden de las medias de la variable dependiente. Esta estrategia permitió convertir las categorías en valores numéricos conservando la información estadística necesaria para su incorporación al modelo de regresión lineal múltiple.

Relaciones entre variables

Se realizó un análisis de correlación entre las variables numéricas con el propósito de identificar la intensidad y dirección de la relación existente entre ellas y la variable dependiente. Este análisis permitió seleccionar las variables con mayor asociación estadística para integrarlas en el modelo de regresión y descartar aquellas con baja relación.

Multicolinealidad

Con el fin de verificar que las variables independientes no presentaran relaciones excesivamente altas entre sí, se evaluó la multicolinealidad mediante el Factor de Inflación de la Varianza (VIF). Los resultados obtenidos indicaron que las variables incluidas en el modelo no presentaban problemas importantes de multicolinealidad, permitiendo una estimación confiable de los coeficientes de regresión.

Modelo de regresión

Se construyó un modelo de regresión lineal múltiple utilizando las variables independientes seleccionadas después del análisis de correlación y la evaluación de multicolinealidad. Posteriormente se analizaron los coeficientes del modelo, sus valores p y la prueba ANOVA para determinar la significancia estadística de las variables y la capacidad explicativa del modelo obtenido.

Supuestos del modelo

Se verificaron los principales supuestos de la regresión lineal múltiple, incluyendo la linealidad entre las variables, la independencia de los errores, la homocedasticidad y la normalidad de los residuos. La validación de estos supuestos permitió confirmar que el modelo construido era adecuado para explicar el comportamiento de la variable dependiente.

Capacidad predictiva

La capacidad predictiva del modelo fue evaluada mediante el coeficiente de determinación (R^2), así como a través del análisis de los errores del modelo. Los resultados permitieron determinar el porcentaje de variabilidad de las calorías quemadas explicado por las variables independientes incluidas en la regresión, mostrando un modelo con una capacidad explicativa adecuada.

Discusión de resultados

Los resultados obtenidos permitieron identificar las variables que presentan una mayor influencia sobre la cantidad de calorías quemadas durante el entrenamiento. El análisis de correlación facilitó la selección de las variables más relevantes, mientras que la evaluación de la multicolinealidad permitió garantizar la estabilidad del modelo. Asimismo, la codificación de las variables categóricas hizo posible incorporarlas al análisis estadístico sin perder información relevante. En conjunto, las decisiones metodológicas adoptadas durante el desarrollo del proyecto contribuyeron a mejorar la capacidad explicativa y predictiva del modelo de regresión lineal múltiple, permitiendo obtener resultados estadísticamente significativos.

Se sugiere reflexionar sobre:

¿De qué manera las decisiones metodológicas influyen en la capacidad explicativa y predictiva del modelo?

Conclusiones

El desarrollo del presente proyecto permitió aplicar la metodología de regresión lineal múltiple para analizar la relación entre diversas variables asociadas al rendimiento físico de los usuarios de un gimnasio y la cantidad de calorías quemadas durante el ejercicio. A través del análisis de correlación, la codificación de variables categóricas, la evaluación de la multicolinealidad y la validación de los supuestos del modelo, fue posible construir un modelo estadístico adecuado para explicar el comportamiento de la variable dependiente.

Los resultados obtenidos demostraron la utilidad de las técnicas de regresión como herramienta para analizar datos multivariados y apoyar la toma de decisiones basada en evidencia. Asimismo, el proyecto permitió fortalecer las competencias en análisis de datos utilizando Python y Google Colab, integrando los conocimientos adquiridos durante el curso en una aplicación práctica.

Alcance metodológico

El estudio se enmarca en un enfoque de modelación estadística aplicada que integra comparación de medias, transformación de variables categóricas, análisis de correlación, evaluación de multicolinealidad y regresión lineal múltiple.

La codificación de variables categóricas basada en el orden de sus medias respecto a la variable dependiente constituye una aproximación con fines formativos. Esta estrategia implica supuestos que deben analizarse críticamente en términos de interpretación, estabilidad del modelo y posible introducción de sesgos.