

Trabajas en una empresa que produce maquinas de ejercicio. Un gimnasio local ha solicitado que las maquinas esten adaptadas a sus metodos de entrenamiento, para esto les ha proporcionado una base de datos. Al gimnasio le interesa predecir las calorías quemadas con la mayor precisión posible sin ser demasiado invasivos con sus clientes.

```
import pandas as pd
link= "https://raw.githubusercontent.com/cortespoalalejandra-
      dotcom/EstadisticaVerano2026/refs/heads/main/GYMMEMBERS/gym_members_exercise_tracking.csv"
df=pd.read_csv(link)
df
```

	Age	Gender	Weight (kg)	Height (m)	Max_BPM	Avg_BPM	Resting_BPM	Session_Duration (hours)	Calories_Burned
0	56	Male	88.3	1.71	180	157	60	1.69	1313.0
1	46	Female	74.9	1.53	179	151	66	1.30	883.0
2	32	Female	68.1	1.66	167	122	54	1.11	677.0
3	25	Male	53.2	1.70	190	164	56	0.59	532.0
4	38	Male	46.1	1.79	188	158	68	0.64	556.0
...	...	...	...	...	...	...	...	...	...
968	24	Male	87.1	1.74	187	158	67	1.57	1364.0
969	25	Male	66.6	1.61	184	166	56	1.38	1260.0
970	59	Female	60.4	1.76	194	120	53	1.72	929.0
971	32	Male	126.4	1.83	198	146	62	1.10	883.0
972	46	Male	88.7	1.63	166	146	66	0.75	542.0

973 rows × 15 columns

```
#1.Establecer variables
x= df ["duracion_sesion_hrs"]
y= df ["calorias_quemadas"]

df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 973 entries, 0 to 972
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0   edad                  973 non-null    int64
1   genero                973 non-null    object
2   peso_kg               973 non-null    float64
3   altura_m              973 non-null    float64
4   max_bpm               973 non-null    int64
5   promedio_bpm          973 non-null    int64
6   reposo_bpm            973 non-null    int64
7   duracion_sesion_hrs   973 non-null    float64
8   calorias_quemadas     973 non-null    float64
9   tipo_entrenamiento    973 non-null    object
10  porcentaje_grasa      973 non-null    float64
11  agua_lts              973 non-null    float64
12  frecuencia_dias       973 non-null    int64
13  nivel_experiencia     973 non-null    int64
14  imc                   973 non-null    float64
dtypes: float64(7), int64(6), object(2)
memory usage: 114.2+ KB

df.describe()
```

	edad	peso_kg	altura_m	max_bpm	promedio_bpm	reposo_bpm	duracion_sesion_hrs	calor
count	973.000000	973.000000	973.000000	973.000000	973.000000	973.000000	973.000000	973.0
mean	38.683453	73.854676	1.72258	179.883864	143.766701	62.223022	1.256423	905.4
std	12.180928	21.207500	0.12772	11.525686	14.345101	7.327060	0.343033	272.6
min	18.000000	40.000000	1.50000	160.000000	120.000000	50.000000	0.500000	303.0
25%	28.000000	58.100000	1.62000	170.000000	131.000000	56.000000	1.040000	720.0
50%	40.000000	70.000000	1.71000	180.000000	143.000000	62.000000	1.260000	893.0

	edad	peso_kg	altura_m	max_bpm	promedio_bpm	reposo_bpm	duracion_sesion_hrs	calor
75%	49.000000	86.000000	1.80000	190.000000	156.000000	68.000000	1.460000	1076.
max	59.000000	129.900000	2.00000	199.000000	169.000000	74.000000	2.000000	1783.

```

#2. Diagrama de dispersión
from matplotlib.lines import lineStyles
import matplotlib.pyplot as plt
#configuración general
plt.figure(
    figsize=(6,4), #tamaño (ancho, alto)
    dpi=100 #resolución
)
#Gráfico de dispersión
plt.scatter(
    x,y,
    marker="o",
    color="yellow",
    edgecolor="purple", #color de borde
    alpha=0.9, #transparencia
    s=60, #tamaño de punto
    label="calorias_quemadas" #etiqueta
)
#plt.plot(
#    x,y_calculada,
#    marker="o",
#    linewidth=2.2,
#    linestyle="--",
#    markersize=5,
#    markerfacecolor="white",
#    markeredgcolor="black",
#    label="Promedio_final"
#)

#)


#Título
plt.title(
    "Gráfico de dispersión",
    fontsize=12, #tamaño de fuente
    fontweight="bold" #bold: negritas
)
#Etiquetas eje x
plt.xlabel(
    "duracion_sesion_hrs",
    fontsize=10,
)
#Etiqueta eje y
plt.ylabel(
    "calorias_quemadas",
    fontsize=10
)
#tamaño de los ticks
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

#Márgenes
plt.margins(x=0.05,y=0.05)
plt.gca().spines[["top", "right"]].set_visible(False)

plt.grid(
    visible=True,
    linestyle="--",
    linewidth=0.7, #ancho de línea
    alpha=0.5, #transparencia
    color="black"
)
#Leyenda
plt.legend(
    fontsize=10,
    loc="best",
    frameon=False
    #bbox_to_anchor=(0.5,-0.15)
)
#Guardar imagen
plt.savefig(
    "Dispersión",

```

```
bbox_inches="tight"
)
```



```
#4. Calcula el coeficiente de correlación e interpreta el resultado
from scipy.stats import pearsonr
r, valor_p=pearsonr(x,y) #p es de prueba de hipótesis
                        # Ho: P=0 No hay correlación (el cambio en una
                        #      variable está vinculado con el cambio en otra variable)
                        # H1: P!=0 Sí hay correlación
print(f"coeficiente de correlación (r):{r:0.4f}")
print(f"valor_p:{valor_p:0.4f}")

coeficiente de correlación (r):0.9081
valor_p:0.0000
```

####4. Interpreta el resultado del coeficiente de correlación

- $r=0.9081$ -> hay correlación.
- El valor $p=0$, entonces H_0 es falsa, por lo tanto sí hay correlación.
- La relación es positiva y fuerte.

```
#5 Calcule el coeficiente de determinación e interprete el resultado.  $\theta = r*r$ 
print(f"coeficiente de determinación:{r**2:0.4f}")
```

coeficiente de determinación:0.8247

####5. Interprete el resultado del coeficiente de determinación

- $r^2=0.8247$
- El modelo explica a un 82.47% la variación de la variable dependiente.

```
#6. Obtenga la recta de regresión ajustada y gráfiquelo sobre el gráfico de
dispersión.
```

```
import statsmodels.api as sm
x_constante=sm.add_constant(x)
modelo=sm.OLS(y,x_constante).fit()
y_calculada=modelo.predict(x_constante)
modelo.params
```

	0	
const	-1.446459	
duracion_sesion_hrs	721.786016	

dtype: float64

```
#6. gráfiquelo sobre el gráfico de dispersión.
```

```
from matplotlib.lines import lineStyles
import matplotlib.pyplot as plt
#configuración general
plt.figure(
    figsize=(6,4), #tamaño (ancho, alto)
    dpi=100        #resolución
)
#Gráfico de dispersión
plt.scatter(
```

```

        x,y,
        marker="o",
        color="yellow",
        edgecolor="black", #color de borde
        alpha=0.9, #transparencia
        s=60, #tamaño de punto
        label="calorias_quemadas" #etiqueta
    )

plt.plot(
    x,y_calculada,
    marker="o",
    color="blue",
    linewidth=2.2,
    linestyle="--",
    markersize=5,
    markerfacecolor="white",
    markeredgecolor="black",
    label="recta de regresión"
)

#Título
plt.title(
    "Gráfico de dispersión",
    fontsize=12, #tamaño de fuente
    fontweight="bold" #bold:negritas
)

#Etiquetas eje x
plt.xlabel(
    "duracion_sesion_hrs",
    fontsize=10,
)

#Etiqueta eje y
plt.ylabel(
    "calorias_quemadas",
    fontsize=10
)

#tamaño de los ticks
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)


#Márgenes
plt.margins(x=0.05,y=0.05)
plt.gca().spines[["top", "right"]].set_visible(False)

plt.grid(
    visible=True,
    linestyle="--",
    linewidth=0.7, #ancho de línea
    alpha=0.5, #transparencia
    color="black"
)

#Leyenda
plt.legend(
    fontsize=10,
    loc="best",
    frameon=False
    #bbox_to_anchor=(0.5,-0.15)
)

#Guardar imagen
plt.savefig(
    "Dispersión",
    bbox_inches="tight"
)

```



```
#7. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de
#regresión ajustada ( b1 )
modelo.conf_int(alpha = 0.05)
```

	0	1
const	-28.738459	25.845542
duracion_sesion_hrs	700.830270	742.741762

```
#8. Calcule los residuales y trace un nuevo gráfico de dispersión.
#Comente, ¿Parece que se verifican los supuestos?
```

```
residuales=modelo.resid

#Gráfico de dispersión
plt.scatter(
    x,residuales,
    marker="o",
    color="pink",
    edgecolor="purple", #color de borde
    alpha=0.9, #transparencia
    s=60, #tamaño de punto
    label="calorias_quemadas" #etiqueta
)

#Título
plt.title(
    "Gráfico de residuales",
    fontsize=12, #tamaño de fuente
    fontweight="bold" #bold:negritas
)

#Etiquetas eje x
plt.xlabel(
    "duracion_sesion_hrs",
    fontsize=10,
)

#Etiqueta eje y
plt.ylabel(
    "calorias_quemadas",
    fontsize=10
)

#tamaño de los ticks
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

#Márgenes
plt.margins(x=0.05,y=0.05)
plt.gca().spines[["top","right"]].set_visible(False)

plt.grid(
    visible=True,
    linestyle="--",
    linewidth=0.7, #ancho de línea
```

```


    alpha=0.2, #transparencia
    color="black"
)
#Leyenda
plt.legend(
    fontsize=10,
    loc="best",
    frameon=False
    #bbox_to_anchor=(0.5,-0.15)
)
#Guardar imagen
plt.savefig(
    "Dispersión",
    bbox_inches="tight"
)

plt.axhline(y=0, color="gray", linestyle="--") #Linea horizontal

#Parece que siguen el supuesto de Linealidad

<matplotlib.lines.Line2D at 0x7f43d9e26e40>

```



```

#9 Test de Shapiro
from scipy.stats import shapiro
estadistico, valor_p=shapiro(residuales)
print(f"Valor_p: {valor_p:0.4f}")
# Ho: Los datos siguen una distribución normal
# H1: Los datos NO siguen una distribución normal

```

Valor_p: 0.0038

####9. Comente el resultado del **Test de Shapiro**

- Como el valor p es mayor al nivel de significancia, $0.0000 < 0.05$
- Entonces H_0 es falsa
- Por lo tanto, los datos no siguen una distribución normal.
- **NOTA:** shapiro es bastante sensible para datos > 30
- Entoces, para comprobar si los datos de verdad NO siguen una distribución normal, debemos checar el HISTOGRAMA y el Q-Q PLOT

```

#Histograma y Q-Q plot
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

```

```

# Visualización: Q-Q plot
sm.qqplot(residuales, line='s')
plt.title("Q-Q plot de residuos")
plt.show()



```

```

# Histograma
sns.histplot(residuales, kde=True)

```

```
plt.title("Histograma de residuos")
plt.show()
```



####Q-Q Plot

- Como podemos ver los datos siguen la linea roja, tiene unas ligeras curvas en las otillas pero en general si siguen la linea roja.
- Se puede decir que los datos siguen una distribución normal.

####Histograma

- Tiene una forma muy parecida a una campana y se ve más o menos simétrico
- Se puede decir que los datos siguen una distribución normal.

```
#10. Test de Breusch-Pagan
from statsmodels.stats.api import het_breuschpagan
estadistico_1, valor_p_1, estadistico_2, valor_p_2 =
    het_breuschpagan(residuales, x_constante)
print(f"valor_p:{valor_p_1:0.4f}")
# Ho: No hay heterocedasticidad (varianza uniforme)
# H1: Hay heterocedasticidad (varianza no uniforme)

valor_p:0.0000
```

####10. Comente el resultado del Test de Breusch-Pagan

- Como el valor p es mayor al nivel de significancia, $0.3795 > 0.05$
- Entonces H_0 es verdadera
- Por lo tanto, No hay heterocedasticidad -> HAY homocedasticidad

- La varianza es uniforme

```
#11. Utiliza la recta de regresión para interpolar dos valores y extrapolar
uno.
#Comenta estos resultados.
df.describe()
```

	edad	peso_kg	altura_m	max_bpm	promedio_bpm	reposo_bpm	duracion_sesion_hrs	calor
count	973.000000	973.000000	973.000000	973.000000	973.000000	973.000000	973.000000	973.0
mean	38.683453	73.854676	1.72258	179.883864	143.766701	62.223022	1.256423	905.4
std	12.180928	21.207500	0.12772	11.525686	14.345101	7.327060	0.343033	272.6
min	18.000000	40.000000	1.50000	160.000000	120.000000	50.000000	0.500000	303.0
25%	28.000000	58.100000	1.62000	170.000000	131.000000	56.000000	1.040000	720.0
50%	40.000000	70.000000	1.71000	180.000000	143.000000	62.000000	1.260000	893.0
75%	49.000000	86.000000	1.80000	190.000000	156.000000	68.000000	1.460000	1076.
max	59.000000	129.900000	2.00000	199.000000	169.000000	74.000000	2.000000	1783.

```
#11
modelo.predict([1,1.9])

array([1369.94697139])

#11
modelo.predict([1,1])

array([720.33955707])

#11
modelo.predict([1,0.3])

array([215.08934593])
```

####11. Resultados

- Interpolando: $f(2.3)=6.91$, $f(3.2222)=9.66$
- Extrapolando: $f(4)=4.52$

```
#12. Realice una tabla ANOVA e interprete el resultado.
from statsmodels.formula.api import ols
# y ~ x
modelo_lineal=ols("calorias_quemadas~duracion_sesion_hrs", data=df).fit()
tabla_anova=sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
duracion_sesion_hrs	1.0	5.958764e+07	5.958764e+07	4568.674447	0.0
Residual	971.0	1.266442e+07	1.304265e+04	NaN	NaN

####12. Interprete el resultado de la **Tabla ANOVA**

- H0: Las variables independientes no explican a la variable dependiente.
- H1: Sí existe relación entre las variables.
- El valor $p=0$
- Valor $p < 0.05$
- H0 es falsa
- Por lo tanto, sí existe relación entre las variables.
- El modelo es significativo :)



**TECNOLÓGICO
NACIONAL DE MÉXICO**



Instituto **Tecnológico**[®]
de Aguascalientes

Tecnológico Nacional de México
Instituto Tecnológico de Aguascalientes

Estadística Inferencial II

Ing. Jose Cruz Muñoz Esparza

Docente

ACTIVIDAD. Gym Members

Estudiante (s):

- 23150464 – Cortes Delgado Paola Alejandra

01 de julio de 2026, Aguascalientes, Ags.



Índice

Introducción	3
Metodología.....	4
Resultados.....	5
Estadísticos principales	5
Gráfico de dispersión	5
Modelo de regresión	6
Gráfico de residuales	6
Predicción	7
Conclusiones.....	8



Introducción

Actualmente, los gimnasios buscan ofrecer programas de entrenamiento personalizados que permitan a sus socios alcanzar sus objetivos de manera más eficiente. Para lograrlo, es importante identificar qué factores influyen en el gasto calórico durante una sesión de ejercicio, ya que esta información facilita el diseño de rutinas acordes con las necesidades de cada persona.

En este estudio se analiza la relación entre la duración de la sesión de entrenamiento y las calorías quemadas, con el propósito de determinar si existe una relación lineal que permita utilizar la duración como una variable predictora del gasto energético. La duración de la sesión representa la variable independiente, mientras que las calorías quemadas corresponden a la variable dependiente.

Conocer la relación entre ambas variables resulta de gran utilidad para el gimnasio FitLife, ya que permitiría estimar el gasto calórico de una sesión sin necesidad de realizar mediciones complejas. Esto facilitaría la elaboración de planes de entrenamiento personalizados, el establecimiento de metas para los usuarios y una mejor planificación de las rutinas de ejercicio.

El objetivo general del análisis es determinar si la duración de una sesión de entrenamiento permite predecir de manera confiable las calorías quemadas mediante un modelo de regresión lineal simple, así como evaluar la calidad y utilidad estadística del modelo obtenido.



Metodología

Para el desarrollo del análisis se utilizó la base de datos Gym Members Exercise Dataset, integrada por 973 registros correspondientes a sesiones de entrenamiento realizadas por miembros de un gimnasio. La información incluye variables relacionadas con las características físicas de los usuarios y su desempeño durante el ejercicio, entre ellas edad, peso, estatura, frecuencia cardíaca, duración de la sesión, tipo de entrenamiento, frecuencia semanal y calorías quemadas.

La variable independiente seleccionada fue la duración de la sesión de entrenamiento (horas), mientras que la variable dependiente fue el número de calorías quemadas durante la sesión.

Con el propósito de evaluar la relación existente entre ambas variables, se aplicó un modelo de regresión lineal simple, técnica estadística que permite estudiar la asociación entre una variable explicativa y una variable respuesta, además de generar una ecuación para realizar estimaciones y predicciones.

La regresión lineal simple fue elegida debido a que el problema de investigación busca determinar si una única variable, la duración del entrenamiento, es suficiente para explicar el comportamiento del gasto calórico. Esta técnica también permite cuantificar la intensidad de la relación entre las variables y evaluar la capacidad predictiva del modelo.

Como parte del procedimiento estadístico se realizaron las siguientes actividades:

- Exploración inicial de la base de datos.
- Obtención de estadísticos descriptivos.
- Elaboración del gráfico de dispersión con la recta de regresión.
- Cálculo del coeficiente de correlación de Pearson (r).
- Obtención del coeficiente de determinación (R^2).
- Estimación de la ecuación de regresión lineal.
- Análisis gráfico de los residuales para verificar la calidad del ajuste.
- Predicción del gasto calórico para un valor específico de duración de entrenamiento mediante la ecuación obtenida.



Resultados

Estadísticos principales

INDICADOR	RESULTADO
Registros Analizados	973
Variable independiente	Duración de la sesión
Variable dependiente	Calorías quemadas
Coeficiente de correlación (r)	0.91
Coeficiente de determinación (r^2)	0.82

Gráfico de dispersión




Ilustración 1 Relación entre la duración de la sesión y las calorías quemadas.

El gráfico de dispersión muestra una tendencia lineal positiva entre la duración de la sesión de entrenamiento y las calorías quemadas. A medida que aumenta la duración del ejercicio, también se incrementa el gasto calórico. La mayoría de los puntos se encuentran cercanos a la recta de regresión, lo que coincide con el coeficiente de correlación obtenido ($r = 0.91$) y sugiere una relación lineal fuerte entre ambas variables.



Modelo de regresión

Ecuación de regresión:

$$\text{Calorías quemadas} = -128.69 + 379.22 \times \text{Duración de la sesión}$$

Gráfico de residuales




Ilustración 2 Gráfico de residuales del modelo de regresión lineal

El gráfico de residuales muestra que los errores del modelo se distribuyen alrededor de la línea horizontal correspondiente al valor cero, sin presentar un patrón sistemático que indique una relación no lineal entre las variables. Aunque se observa una ligera mayor dispersión en las sesiones de mayor duración, el comportamiento general de los residuales sugiere que el modelo lineal proporciona un ajuste adecuado para explicar la relación entre la duración de la sesión y las calorías quemadas. Esto respalda la confiabilidad del modelo para realizar estimaciones dentro del rango de datos analizado.



Predicción

Duración	Calorías estimadas
1.5 hrs.	440.14

Con la ecuación de regresión obtenida fue posible realizar una estimación del gasto calórico para una sesión de entrenamiento con una duración de 1.5 horas. El modelo predijo que un usuario quemaría aproximadamente 440.14 calorías durante dicho entrenamiento. Esta predicción demuestra la utilidad práctica del modelo de regresión lineal, ya que permite estimar el gasto calórico de una sesión a partir de su duración. Aunque el resultado corresponde a una estimación y puede variar según las características individuales de cada persona, el modelo constituye una herramienta útil para apoyar la planificación de rutinas de entrenamiento y establecer objetivos de gasto energético de manera sencilla y fundamentada.



Conclusiones

El análisis estadístico permitió comprobar que existe una relación positiva entre la duración de la sesión de entrenamiento y las calorías quemadas. Los resultados muestran que, conforme aumenta el tiempo dedicado al ejercicio, también se incrementa el gasto energético, lo que coincide con el comportamiento esperado desde el punto de vista fisiológico.

La duración del entrenamiento explica una parte importante de la variabilidad de las calorías quemadas, lo que confirma que esta variable puede utilizarse como un buen predictor dentro de un modelo de regresión lineal simple. Asimismo, el valor obtenido para el coeficiente de correlación evidencia una asociación significativa entre ambas variables.

El análisis de los residuales indica que el modelo presenta un ajuste adecuado y que las estimaciones obtenidas son consistentes para los datos analizados, por lo que puede considerarse una herramienta confiable para realizar predicciones generales. Sin embargo, el modelo presenta algunas limitaciones, ya que el gasto calórico también depende de otros factores como el peso corporal, la edad, el sexo, la frecuencia cardíaca, la intensidad del ejercicio y el tipo de entrenamiento realizado. Por esta razón, aunque la duración constituye un predictor importante, no explica por sí sola la totalidad del comportamiento observado.

Como recomendación para el gimnasio FitLife, se sugiere utilizar este modelo como una herramienta inicial para estimar el gasto calórico de los usuarios y apoyar el diseño de rutinas personalizadas. No obstante, para obtener predicciones más precisas sería conveniente desarrollar en el futuro un **modelo de regresión lineal múltiple** que incorpore variables adicionales como el peso, la frecuencia cardíaca y el tipo de entrenamiento, mejorando así la capacidad predictiva y la personalización de los programas de ejercicio.